


Metodología de Análisis de Componentes Principales (PCA) en Señales EMG

24 de junio de 2026

1. Fundamentos y Flujo de Trabajo

El Análisis de Componentes Principales (PCA) es un algoritmo de reducción de dimensiones que busca proyectar vectores de alta dimensionalidad (espacio de activaciones musculares) hacia un plano 2D o 3D maximizando la varianza explicada.

A diferencia de algoritmos topológicos como UMAP, PCA es una transformación estrictamente lineal y ortogonal, lo que garantiza que las distancias proyectadas conservan una correlación directa con la distancia euclidiana en el espacio original. Si dos puntos colapsan en el mismo cluster, implica una altísima similitud morfológica y temporal en la activación fisiológica subyacente.



2. Modo Supervisado vs No Supervisado

PCA es por naturaleza un algoritmo **no supervisado**. Matemáticamente ignora cualquier etiqueta asociada a los pulsos (como la vocal pronunciada) y se enfoca exclusivamente en la varianza estructural de los vectores mioeléctricos.

En nuestro pipeline, la designación de PCA como "*Supervisado*" (mediante el flag `_Sup`) no altera la transformación algebraica. Su propósito es netamente organizativo y visual:

- **Coloración:** Utiliza las etiquetas reales para pintar las nubes de dispersión, permitiendo la auditoría cruzada entre los clusters naturales del músculo y la vocal real fonada.
- **Exportación Orientada a Clasificadores:** Garantiza que el vector resultante es resguardado como conjunto de entrenamiento con etiquetas explícitas (Dataset etiquetado) para futuros modelos de Machine Learning.

3. Interpretación Geométrica: 2D frente a 3D

- **Proyección 2D (PC1 vs PC2):** Extrae las dos direcciones de mayor divergencia estadística en el dataset. Su simplicidad lo hace ideal para reportes y estimaciones de fronteras de decisión estáticas.
- **Proyección 3D (PC1 vs PC2 vs PC3):** Agrega profundidad matemática. Fenómenos que aparentan colisionar (solapamiento) en el espacio 2D debido al efecto de la "sombra de proyección", se revelan como clusters independientes al rotar el tercer eje. El hiperplano de separación se vuelve mucho más representativo de la realidad de alta dimensionalidad.