


# Metodología de Análisis Topológico y Clustering con UMAP

17 de junio de 2026

## 1. Diagrama de Flujo del Algoritmo UMAP

El siguiente diagrama detalla el proceso de acondicionamiento de señales y transformación a espacios de alta dimensionalidad para su posterior reducción topológica en un plano bidimensional.



## 2. Explicación Detallada de la Metodología

### 2.1. 1. Construcción del Espacio de Características

Para que el algoritmo de agrupamiento pueda clasificar los pulsos electromiográficos, primero es necesario traducir cada evento temporal a un vector numérico  $X_i \in \mathbb{R}^D$ , donde  $D$  es el número de dimensiones. El algoritmo provee dos métodos:

- **Modo Picos (Baja Dimensión,  $D = 3$ ):** Solo se extrae el valor máximo normalizado de cada canal. Es un modelo robusto pero descarta la morfología de contracción.
- **Modo Forma de Onda (Alta Dimensión,  $D \gg 3$ ):** Se toma la totalidad de muestras del pulso de cada canal y se concatenan en serie (*flatten*). Si un pulso tiene  $M$  muestras por canal y existen  $C$  canales, la dimensión del vector será  $D = M \times C$ . Esto preserva asimetrías y tiempos de rampa vitales para detectar diferencias sutiles entre vocales.

El resultado de procesar todos los pulsos válidos es una matriz  $X \in \mathbb{R}^{N \times D}$ , junto con un vector de etiquetas  $Y \in \mathbb{R}^N$  que contiene la vocal asociada a cada pulso.

### 2.2. 2. Matemática de UMAP

Uniform Manifold Approximation and Projection (UMAP) es un algoritmo de reducción de dimensionalidad no lineal fundado en la topología algebraica y la geometría Riemanniana. Consta de dos fases principales:

#### 2.2.1. a) Construcción del Grafo Topológico Local

UMAP asume que los datos se distribuyen uniformemente sobre una variedad de Riemann local. Calcula la distancia a los  $k$  vecinos más cercanos (*n-neighbors*) para cada punto  $X_i$ , y construye un *Fuzzy Simplicial Set* (un grafo difuso). El peso de la arista entre dos puntos se basa en una distribución exponencial decreciente de la distancia:

$$p_{i|j} = \exp \left( -\frac{\max(0, d(x_i, x_j) - \rho_i)}{\sigma_i} \right)$$

Donde  $\rho_i$  es la distancia al vecino más cercano (garantizando conectividad local) y  $\sigma_i$  es un factor de escala normalizado empíricamente.

#### 2.2.2. b) Optimización Dimensional (Proyección)

Una vez construido el grafo en alta dimensionalidad, UMAP inicializa un grafo equivalente en un espacio de baja dimensión (2D)  $Y_i \in \mathbb{R}^2$ . Luego minimiza la Entropía Cruzada difusa (*Fuzzy Cross Entropy*) entre la estructura del grafo de alta dimensión ( $p_{ij}$ ) y el de baja dimensión ( $q_{ij}$ ) mediante descenso de gradiente estocástico:

$$C_E(X, Y) = \sum_{i \neq j} \left( p_{ij} \log \left( \frac{p_{ij}}{q_{ij}} \right) + (1 - p_{ij}) \log \left( \frac{1 - p_{ij}}{1 - q_{ij}} \right) \right)$$

Esto fuerza a que los puntos cercanos en el espacio de características EMG se atraigan en el plano 2D, y los puntos lejanos se repelan, revelando clústeres intrínsecos de cada vocal.

## 2.3. 3. Sintonización de Hiperparámetros

La topología generada por UMAP es altamente sensible a dos parámetros matemáticos principales que determinan el equilibrio entre la micro-estructura local y la macro-estructura global de los pulsos:

- **Vecinos (*n\_neighbors*):** Determina la cantidad de puntos cercanos que UMAP considera al construir el grafo difuso (radio de conectividad local).
  - *Valores bajos (5 - 15):* UMAP se concentra de forma miope en la estructura local. Es ideal para descubrir si existen micro-variaciones o subclústeres (por ejemplo, si un sujeto pronunció la misma vocal con dos intensidades musculares diferentes). Sin embargo, puede fragmentar clústeres grandes.
  - *Valores altos (30 - 50+):* Empuja a UMAP a mirar la imagen global, forzando a que pulsos de la misma clase topológica se comporten como una sola masa. Es el valor recomendado para separar las 5 vocales principales de forma robusta frente al ruido.
- **Distancia Mínima (*min\_dist*):** Controla la cercanía mínima permitida entre puntos en la proyección final (2D/3D). Actúa como una fuerza de repulsión en el espacio reducido.
  - *Valores cercanos a 0.0:* Los puntos colapsan unos sobre otros si son topológicamente idénticos. Es excelente para lograr clústeres compactos y densos que facilitan la clasificación por fronteras duras.
  - *Valores altos (ej. 0.5):* Permite que los puntos respiren”, esparciendo el clúster. Es útil si se busca interpretar la varianza natural y la distribución interna de una misma vocal en lugar de solo separarla.

## 2.4. 4. UMAP No Supervisado vs. Supervisado (SUMAP)

- **No Supervisado:** La métrica topológica ignora las etiquetas  $Y$ . Si el algoritmo agrupa puntos de la misma vocal, demuestra que hay separabilidad natural en la señal física sin forzarla algorítmicamente.
- **Supervisado (SUMAP):** La métrica de distancia de alta dimensionalidad se penaliza usando el vector  $Y$ . Si dos puntos pertenecen a vocales distintas, su distancia se considera infinitamente grande. Esto fuerza al *manifold* a romperse entre clases, generando mapas visuales con separabilidad de clases extrema, ideal para auditar la pureza del subespacio inter-clase de cara a modelos de Machine Learning.

## 2.5. 5. Métrica de Calidad: Silhouette Score

Para no depender exclusivamente de la apreciación visual subjetiva del gráfico, el motor computa el **Coefficiente de Silueta** (*Silhouette Score*) sobre la proyección 2D final. Esta métrica matemática evalúa la consistencia intrínseca de los clústeres generados, arrojando un valor entre -1 y 1:

- **Cercano a 1.0:** Indica que los pulsos están estrechamente unidos a los de su misma vocal y muy alejados de las otras vocales. Es el escenario ideal de separabilidad pura.

- **Cercano a 0.0:** Denota superposición de fronteras. UMAP no logra decidir con claridad y las nubes de puntos se tocan.
- **Negativo (-1.0):** Representa un fallo total, donde pulsos de una vocal quedaron atrapados topológicamente dentro del clúster de otra vocal.

## 2.6. 6. Exportación y Auditoría de Datos

El sistema garantiza la trazabilidad del proceso aislando los resultados en la misma carpeta de la sesión original (bajo el subdirectorio */UMAP/*). El pipeline genera automáticamente:

- **Imágenes 2D y 3D:** Representaciones visuales coloreadas usando la paleta estándar de alto contraste de Matplotlib (`tab10`).
- **Reporte PDF:** Este mismo formato en LaTeX autogenerado con la ficha técnica del experimento, separando claramente qué mediciones entraron al algoritmo (con su eficiencia en el filtro SNR) y cuáles fueron descartadas.
- **Matriz CSV Cruda:** Un archivo tabular que contiene la matriz de características exacta que el algoritmo UMAP digirió (luego del preprocesamiento y limpieza de ruido), permitiendo auditar pulso por pulso.