

Decodificación de vocales del español mediante sEMG y algoritmos de reducción de dimensionalidad

Braunstein Lucas, Prado Rodriguez Santiago

braunstein.lucas@gmail.com, santiagopradorodriguez@gmail.com

Directora: Ana Amador

Colaborador: Felipe Cignoli

Profesora responsable: Dra. Andrea Bragas

Laboratorio 7 1°C 2026 - Laboratorio de Sistemas Dinámicos

Departamento de Física, FCEyN, UBA

07 de Agosto de 2026

Resumen

En este trabajo se investigó la viabilidad de clasificar las cinco vocales del español utilizando electromiografía superficial (sEMG). Para ello, se diseñó e implementó un sistema integral de hardware y software (*Nándú LSD*) capaz de registrar sincrónicamente la actividad de tres músculos: *Orbicularis Oris*, *Depressor Anguli Oris* y *Mylohyoid*. Mediante un enfoque de análisis de complejidad incremental (discretización por umbrales, PCA y sUMAP), se evaluó la separabilidad del espacio fonético vocálico. Los resultados mostraron que el sistema posee la sensibilidad suficiente para aislar topológicamente *grandes grupos* fonéticos (“A”, “E-I” y “O-U”), lo que permitió clasificar con alta precisión los gestos motores extremos, “A”, “I” y “U”, alcanzando predicciones de hasta el 100 % utilizando sUMAP. Sin embargo, las vocales intermedias, “E” y “O”, evidenciaron un solapamiento persistente que limitó la precisión globalmente. Estas barreras predictivas abrieron dos interpretaciones: que es necesario explorar una triada muscular alternativa, o bien es necesaria la incorporación de un cuarto canal electromiográfico. De manera transversal, es necesario mejorar el montaje experimental con el objetivo de mitigar ruidos eléctricos y garantizar la adherencia de los electrodos, para mejorar la reproducibilidad. A pesar de estas limitaciones técnicas, el trabajo confirma la factibilidad de aislar identidades fonéticas discretas a partir de dinámicas musculares continuas.

1. Introducción

Las tecnologías actuales de Reconocimiento Automático del Habla (RAH) dependen exclusivamente de la captura de señales acústicas. Esto impone limitaciones en escenarios con ruido de fondo adverso, en situaciones que requieren privacidad (donde el habla puede molestar o ser interceptada), y fundamentalmente, excluye a personas con discapacidades vocales o neurológicas que han perdido la capacidad de fonación. Como alternativa, las Interfaces de Habla Silenciosa (Silent Speech Interfaces, SSI) proponen decodificar el habla capturando la actividad preacústica del usuario. Entre las técnicas más viables destaca la electromiografía superficial (sEMG), un método no invasivo que registra los potenciales de activación de los músculos articulatorios faciales y del cuello (Janke et al., 2017 [1]; Wand et al., 2013 [2]).

Si bien los sonidos de todos los idiomas se describen mediante un conjunto finito y discreto de símbolos,

los *fonemas*, estos son producidos por movimientos continuos y altamente complejos del tracto vocal (Assaneo et al., 2019 [3]). La fonética clásica ha intentado mapear las vocales en espacios de baja dimensión (como las frecuencias de los formantes acústicos o la posición de la lengua), pero asumiendo siempre la naturaleza continua de los cambios morfológicos. Trabajos recientes han propuesto una alternativa a esta visión, demostrando que la dinámica continua de los articuladores puede contraerse y describirse en un espacio de baja dimensión de “coordenadas motoras discretas” binarias (Assaneo et al., 2013 [4]).

Por otro lado, trabajos recientes de RAH basados en sEMG han logrado clasificar palabras utilizando técnicas de reducción de dimensionalidad sobre músculos faciales específicos (Ratnovsky et al., 2021 [5]), pero sin profundizar en si la identidad discreta de los fonemas básicos puede extraerse directamente de la actividad eléctrica muscular subyacente.

Este trabajo propone “tender un puente” entre ambos enfoques: investigar si es posible aislar la identidad discreta de los fonemas puramente a partir de la actividad electromiográfica continua, con la novedad de que este estudio trabaja exclusivamente la fonética del idioma español. Para ello, se registró la señal sEMG de tres músculos articulatorios (*Orbicularis Oris*, *Depressor Anguli Oris* y *Mylohyoid*), cuya participación funcional ha sido descrita en investigaciones previas sobre el reconocimiento del habla [5, 1], durante la fonación de las cinco vocales del español.

Para posibilitar este estudio, se desarrolló un sistema integral de hardware y software denominado “*Nandú LSD*”. La medición de los músculos se sostiene en parte sobre este sistema que consta de un equipo amplificador sEMG de tres canales, diseñado y ensamblado en un gabinete autónomo. Este dispositivo opera en conjunto con una placa de adquisición de datos (DAQ), una interfaz de audio y un micrófono para el registro sincrónico de la voz. A su vez, el acondicionamiento, visualización y procesamiento de esta información se centralizan en una aplicación de software diseñada específicamente para este proyecto.

El objetivo principal es evaluar la viabilidad de separar y clasificar estas vocales a partir de sus “patrones de activación muscular” o *firmas musculares*. Para ello, se diseñó una metodología de complejidad algorítmica incremental que recorre tres métodos distintos de análisis: primero se aplicó un Método de Umbrales; luego se incorporó el Análisis de Componentes Principales (PCA), aumentando la complejidad hacia una reducción de dimensionalidad lineal que aún conserva una alta interpretabilidad fisiológica de los resultados; finalmente, se exploró el límite de la separabilidad mediante sUMAP (Supervised Uniform Manifold Approximation and Projection), una técnica no lineal que, si bien sacrifica la interpretabilidad directa de las variables, posee el potencial topológico de separar superposiciones en los datos que los métodos anteriores podrían no lograr. Esta progresión permite no solo buscar el mejor rendimiento en cuanto a clasificación, sino que también comprender qué nivel de procesamiento matemático es verdaderamente necesario para decodificar la actividad motora del tracto vocal.

2. Desarrollo experimental

El desarrollo experimental comprendió tres etapas: la construcción y ensamblaje final de un amplificador di-

ferencial de tres canales, la implementación del software para la adquisición y el procesamiento de mediciones, y el diseño del montaje y protocolo experimental. La integración del hardware y software desarrollado dio lugar a un sistema de registro unificado que se denominó *Nandú LSD*.

2.1. Hardware

El montaje experimental integra tanto instrumentación comercial como electrónica de diseño propio. Respecto a esta última, la placa del amplificador diseñada en Laboratorio 6 [6] fue integrada dentro de un gabinete de contención. Dicho chasis fue modificado para agregarle conectores hembra mini-XLR (comúnmente denominados mini-canon) de tres pines, un conector *jack* de 6.5 mm, un interruptor de encendido con indicador LED, y tres terminales hembra BNC. Adicionalmente, se incorporaron soportes para dos baterías de 9 V, asegurando un dispositivo compacto y de alimentación autónoma.

Por otro lado, se ensamblaron tres cables trenzados y mallados para conectar los electrodos al amplificador (uno por canal). Se utilizaron conectores macho mini-XLR para transmitir la señal positiva ($V+$), la señal negativa ($V-$) y enlazar el recubrimiento de papel aluminio como blindaje a tierra (GND). En el extremo opuesto, el cableado de cobre fue soldado a broches a presión metálicos para facilitar el anclaje a los electrodos. La unión fue reforzada mediante un revestimiento aislante y fijada con cemento de contacto. El aspecto final del equipo ensamblado se expone en la Fig. (1).

2.2. Software

La parte que completa a *Nandú LSD* es su software. Debido a la necesidad de medir simultáneamente 4 canales de información, 3 músculos y un micrófono, se desarrolló un software propio (denominado también *Nandú LSD*) con el objetivo fundamental de poder adquirir y visualizar en tiempo real tantos canales como posea la tarjeta conversora analógico-digital (DAQ). Además, el sistema automatiza el procedimiento experimental y los procesos de grabación, como también permite visualizar y analizar, así como organizar adecuadamente en base de datos para posteriores análisis. El software se encuentra en este [repositorio](#) de GitHub.




Figura 1: Imágenes del equipo que se desarrolló. (a) Vista superior del amplificador de 3 canales *Ñandú LSD*. (b) Vista lateral con las entradas de los electrodos, y pulsador de encendido y apagado. (c) Vista lateral con salidas de los canales de amplificación. Código QR al repositorio del proyecto en GitHub. (d) Juego de cables trenzados y mallados. (e) Extremo del cable conector al amplificador. (f) Extremo del cable conector a los electrodos.

2.3. Medición de vocales con sEMG

Se midieron los músculos *Depressor Anguli oris*, *Orbicularis Oris* y *Mylohyoid* en función del tiempo, y se grabó el sonido emitido. Se utilizaron dos electrodos (por ser una amplificación diferencial) por cada músculo, posicionando la referencia (*GND*) en la apófisis mastoideas (hueso detrás de la oreja), como se puede ver en la Fig. (2). Se conectaron los electrodos al equipo *Ñandú LSD* y la salida de este a la placa de adquisición *NI-DAQ-USB-6212* [7] que se conectó a una computadora. Para grabar la voz se utilizó un micrófono direccional *TAKSTAR SGC 568* [8], que se conectó a una placa preamplificadora de audio *Behringer TUBE ULTRAGAIN MIC100* [9]. La salida de este preamplificador fue conectada a la placa de adquisición ya mencionada (ver Fig. 2). Los electrodos utilizados fueron los *Medi-Trace* [10], que no fueron reutilizados. Se definió como “sesión” cada experimento que utilizó electrodos nuevos. Se realizaron tres sesiones en días y horarios diferentes sobre un único sujeto experimental varón de 25 años, hablante nativo de español rioplatense, donde se midieron, en total y con un metrónomo de 30 BPM (para reproducir a ritmo constante cada vocal), 118 pronunciamientos de cada vocal: “A”, “E”, “I”, “O” y “U”. Todas las señales eléctricas fueron digitalizadas a una frecuencia de muestreo de 2000 Hz.

2.3.1. Protocolo y procesamiento de datos

Se desarrolló un protocolo, tanto para la adquisición de la señal como para el procesamiento, con el objetivo de poder reproducir las mediciones considerando el ruido asociado a los electrodos [11] y la variabilidad intrínseca de señales biológicas. El protocolo constó entonces de los siguientes pasos: (1) **preparación de electrodos**, se recortaron los pares de electrodos sin despegarlos, se colocaron los broches de presión y cinta *3M DURAPORE* antes de la adhesión facial; (2) **entrenamiento y calibración**, se realizó una práctica de vocales sincronizada con un metrónomo de 30 BPM y se ajustó la ganancia del preamplificador a un nivel promedio de -18 dB para optimizar la relación señal-ruido (SNR); (3) **preparación del sujeto**, este se lavó el área con detergente especial, se secó con gasa y frotó más localizadamente con alcohol al 70 % para secar aún más la piel; (4) **colocación de electrodos**, despegándolos primero para luego presionarlos contra los músculos; (5) **configuración de captura**, se ajustó el patrón polar del micrófono en modo cardioide; y (6) **validación de canales EMG**, donde se verificó la señal solicitando al sujeto tragar saliva (para activar el músculo *Mylohyoid*) y realizar una sonrisa exagerada o mostrar los dientes (para activar el *Depressor* y el *Orbicularis*).

Con respecto al procesamiento, a las cuatro señales




Figura 2: (a) Se señalan los músculos medidos. (b), (c) y (d) esquemas ilustrativos de cómo se posicionaron los electrodos en los músculos. (e) Set experimental de la medición. Los electrodos se conectaron al amplificador *Nándú LSD*, que fue conectado a la placa de adquisición *NI DAQ USB-6212*, y esta a una computadora. El micrófono *TAKSTAR SGC 568*, utilizado para grabar la voz, se conectó a una placa pre-amplificadora *Behringer TUBE ULTRAGAIN MIC100*, que fue conectada a la mencionada placa de NI.

(una de micrófono y tres musculares), se les aplicó un filtro *notch* en 50 Hz para eliminar el ruido de línea, un filtro *pasabanda* para atenuar la componente de continua que deriva de la interfaz electrodo con piel, y un suavizado por RMS (*Root Mean Square*) para calcular su envolvente. Luego se segmentó cada señal en “ventanas” de período dictado por el metrónomo de 30 BPM, y se calcularon los picos máximos en cada una. Así se obtuvo una triada de ventanas por cada pronunciación. Se definió como “pulso” a cada señal dentro de cada ventana, es decir, a cada pronunciación de vocal. A partir de acá, la “preparación” varía según el método de análisis utilizado.

Discretización por umbrales

El objetivo de este método es convertir la señal de cada músculo en un estado lógico binario (1 si supera un dado umbral y 0 si no), generando un código discreto de activación muscular para cada vocal. Entonces, primero se descartaron los pulsos cuyo valor de SNR fue inferior a un límite preestablecido. Luego, a cada pulso se le restó el *ruido basal* identificado en cada ventana. Después, la amplitud de la envolvente de cada pulso se normalizó según el músculo de mayor amplitud en cada ventana. Todo esto permitió que las mediciones de pronunciación sean comparables entre sí.

Para definir el umbral se realizó una búsqueda iterativa sobre todas las mediciones para encontrar un umbral que asocie a cada vocal con un código discreto único: si el pulso supera el umbral se le asigna un “1” y en caso contrario un “0”, definiendo la vocal mediante el vector de mayor frecuencia de aparición. Es decir, mediante un barrido sistemático de valores, el algoritmo evaluó la activación de cada músculo y seleccionó el valor de umbral que minimiza la asignación de códigos idénticos a vocales distintas. De esta manera, el éxito en la “separación de vocales” radica en obtener vectores binarios únicos y distinguibles para cada fonema.

Preparación de datos para reducción de dimensionalidad

Para aplicar métodos matemáticos más complejos, PCA y sUMAP, se requirió un formateo de los datos distinto al utilizado en el método de umbrales. Se emplearon los picos de la señal del micrófono como ancla temporal para alinear todas las ventanas en el cero, preservando así los desfases relativos de la contracción de cada músculo. A cada ventana (previamente restada su línea base y normalizada por amplitud) se la remuestreó a una cantidad fija de N puntos mediante una transformada rápida de Fourier (FFT). Finalmente, se construyó un vector de características concatenando los N puntos de los tres músculos, generando un arreglo de tamaño $3 \times N$ por medición. La concatenación de todos estos vectores conformó la matriz de datos de entrada.

Análisis de Componentes Principales (PCA)

En congruencia con la complejidad algorítmica incremental propuesta, se evaluó en primera instancia el Análisis de Componentes Principales (PCA) [12]. Al ser una transformación lineal, PCA es un método altamen-

te interpretable que permite analizar qué tan separables son de por sí las firmas musculares en el espacio de mayor varianza. Sobre los datos proyectados en este espacio latente, se utilizó un algoritmo de “clustering” GMM (Gaussian Mixture Models [13]) para agrupar los datos de forma no supervisada en 5 clases. Para poder cuantificar la tasa de aciertos, se aplicó el *algoritmo húngaro* [14], un método que encuentra el emparejamiento óptimo entre los clústeres generados por GMM y las verdaderas etiquetas de las vocales. A través de este emparejamiento se definieron las fronteras de decisión de las zonas correspondientes a cada vocal.

UMAP Supervisado (sUMAP)

Finalmente, con el propósito de explorar el límite de la separabilidad, se aplicó sUMAP (*Supervised Uniform Manifold Approximation and Projection*) [15]. A diferencia de PCA, sUMAP es un método de reducción de dimensionalidad no lineal. Si bien sacrifica la interpretabilidad fisiológica directa de los ejes resultantes, posee un enorme potencial topológico para “desenredar” superposiciones complejas en los datos. Para garantizar la validez de los modelos y evitar la fuga de datos (*data leakage*), de una muestra de 590 mediciones de vocales a lo largo de 3 sesiones (el total de mediciones), se destinó un 80 % para el conjunto de entrenamiento (*training set*), y el 20 % restante para el conjunto de prueba (*test set*). El algoritmo sUMAP recibió únicamente la matriz de los datos de entrenamiento junto con sus respectivas etiquetas (método supervisado) para generar un espacio latente optimizado. Sobre dicha proyección, se configuró un clasificador *K-Nearest Neighbors* (K-NN [16]) para trazar las fronteras de decisión. Por último, se proyectaron los datos del conjunto de prueba (las mediciones nunca antes vistas por el algoritmo) sobre este mismo espacio para evaluar dentro de qué fronteras caían, determinando así la capacidad de predicción y generalización del modelo.

Cabe destacar que, tanto para los algoritmos aplicados sobre PCA como para los de sUMAP, se ajustaron sistemáticamente los parámetros de procesamiento e hiperparámetros de configuración para maximizar la tasa de acierto en la clasificación. Este proceso de optimización determinó que el rendimiento más alto se alcanza calculando la envolvente de la señal con una ventana RMS de 90 ms, y aplicando un remuestreo final a $N = 20$ puntos por canal, lo que consolida un vector espacial de 60 dimensiones por cada pronunciación evaluada.

3. Resultados

La naturaleza intrínseca de las señales biológicas, sumada al ruido eléctrico y de la interfaz piel electrodo [11], supuso un gran desafío para la reproducibilidad del experimento. Sin embargo, gracias al protocolo de medición desarrollado, se lograron adquirir señales con un alto valor de (SNR). Esto permitió observar visualmente que los músculos se activan formando “estructuras” o “firmas” temporales definidas para cada vocal en particular. A modo de ejemplo, la Fig. (3) ilustra la señal cruda y la señal suavizada, con filtros notch y pasabanda, de dos músculos durante la pronunciación de la vocal “I”.




Figura 3: Muestra de señales que se obtienen en cada medición y preprocesamiento, para 20 vocalizaciones de la vocal “I”. Se eligieron solo las señales de los músculos *Mylohyoid* y *Depressor anguli oris*. (a) Se observan las señales sin preprocesamiento. La barra vertical de 700 μV representa la amplitud de la señal. (b) Se observan las señales preprocesadas: se les aplicó un filtro notch de 50 Hz, un filtro pasabanda con frecuencias de corte en 20 Hz y 50 Hz, y se les aplicó un suavizado por media móvil con una ventana de, en esta figura por ejemplo, 150 ms para calcular su envolvente. La barra vertical de 100 μV representa la amplitud de la señal.

3.1. Discretización por umbrales

La Fig. (4) muestra el resultado tras aplicar el método de umbrales para la letra “O”.

Al analizar la distribución de frecuencias de los vectores obtenidos para todo el conjunto de datos, se observó una notable superposición que impidió una clasificación biunívoca. En primer lugar, el vector (1, 1, 1) tuvo un peso representativo en las cinco vocales: constituyó la moda principal de la vocal “E” (31.7 %) y alcanzó frecuencias elevadas en “I” (36.6 %), “O” (28.8 %), “U” (28.2 %) y “A” (20.0 %).

A esta ambigüedad global se sumaron cruzamientos específicos. Por un lado, la vocal “O” dividió su distribución casi equitativamente entre el vector (1, 0, 1) (36.0 %) y el (0, 1, 1) (35.2 %), coincidiendo este último con la moda principal de la “U” (51.6 %). Por otro lado, la moda principal de la “I”, el vector (0, 1, 0) (53.0 %), apareció como la segunda configuración más frecuente de la “E” (30.0 %). Esta recurrencia de vectores compartidos muestra que la discretización temporal por umbrales resulta insuficiente para diferenciar las cinco vocales en simultáneo.




Figura 4: Discretización por umbrales para una medición de la vocal “O”. La amplitud dentro de cada ventana (pulso) se normaliza independientemente respecto al máximo de los tres canales musculares. La línea horizontal representa el umbral optimizado por músculo para minimizar asignaciones ambiguas entre vocales. Si el pulso supera el umbral se le asigna un “1” (verde) y en caso contrario un “0” (rojo), definiendo la vocal mediante el vector binario de mayor frecuencia de aparición. En esta figura, el vector asociado a la “O” es el (1, 0, 1).

Una revisión fisiológica de las mediciones explica estos solapamientos [17]: la activación muscular es parecida para fonemas morfológicamente similares. Por ejemplo, en la “O” y la “U” (vocales cerradas/redondeadas) predominan el *Depressor* y el *Orbicularis*, mientras que en la “E” y la “I” (vocales frontales/estiradas) domina el *Depressor*. Esto sugiere dos hipótesis: o bien la variabilidad de amplitud de estos tres músculos no aporta la información suficiente para separar las cinco clases, requiriendo un cuarto músculo que añada una nueva dimensión geométrica al problema o simplemente cambiar de músculos; o bien es el método por umbrales el que carece de la sensibilidad necesaria.

Pueden estar sucediendo ambas hipótesis. Si se restringe el problema y se retiran del análisis las vocales en conflicto (por ejemplo, omitiendo la “O” o la “U”, así como la “E” o la “I”), la tasa de frecuencia representativa aumenta drásticamente. Es decir, el método de umbrales es funcional para diferenciar subgrupos o pares de vocales muy distintas, pero no posee la robustez necesaria para clasificar el espacio vocálico completo de forma individual.

3.2. PCA

En la Fig. (5) se observan los resultados de proyectar los datos en el espacio bidimensional de mayor varianza generado por el PCA, método lineal, junto con las fronteras de decisión trazadas por el algoritmo GMM [13] para los cinco *clusters*.

En sintonía con las limitaciones observadas en el método de umbrales, la distribución geométrica expone la formación de tres *grandes grupos*: un grupo para la vocal “A”, otro para las vocales “E-I”, donde también se solapan algunas “A”, y un tercer grupo solapado para “O-U”. Una de las métricas analizables es la distancia euclidiana entre los centroides de las clases, donde valores cercanos a 1 indican un alto grado de separabilidad y valores cercanos a 0 reflejan un fuerte solapamiento. Mientras que la distancia promedio entre los distintos *grandes grupos* ronda el 1.13, lo que indica una clara separabilidad, la distancia se reduce a 0.75 entre la clase “A” y el gran grupo “E-I”.

Para evaluar el solapamiento entre clases como su dispersión interna, se calculó el coeficiente de *Silhouette* [18], una métrica que varía entre -1 y 1 . En esta escala, un valor cercano a “1” indica que los datos de una clase están muy cohesionados y perfectamente aislados, valores cercanos a “0” indican que los datos se ubican sobre la




Figura 5: Análisis PCA en 2D de las señales EMG. Los romboides indican el centroide de cada *cluster* para cada vocal. Las zonas con color de fondo muestran cómo el algoritmo GMM separa los grupos en fronteras de decisión, las cuales delimitan las zonas donde hay mayor probabilidad de que un punto pertenezca a esa vocal. Si un punto cae en una zona de distinto color a su etiqueta real, se considera un error de clasificación y se lo asume como la vocal correspondiente a dicha zona.

misma frontera de decisión, y valores negativos reflejan solapamientos claros. El puntaje global obtenido para el espacio bidimensional fue de 0.20, lo que quizás muestra que la activación muscular forma un espacio carente de “clústeres” compactos y totalmente aislados. Al analizarlo por vocal, los resultados reflejan lo que se observa en la Fig. (5): la clase “I” (0.44) es la más compacta y aislada, seguida por la “A” (0.24). En contraste, las vocales con mayor conflicto topológico reportan valores cercanos a cero: “O” (0.12), “U” (0.10) y “E” (0.01). Es decir, las mediciones de estas tres vocales no se agrupan de manera compacta, ubicándose mayoritariamente en los límites de decisión de las clases vecinas, algo particularmente evidente en la “E”.

Estos resultados podrían sugerir que el espacio latente generado por el PCA no representa únicamente varianza eléctrica aleatoria, sino que podría estar capturando, de forma simplificada, las restricciones “biomecánicas” de los músculos involucrados. Las agrupaciones mejor definidas parecen corresponder a “gestos motores extremos” y diferenciables: la “A” requiere la apertura de la mandíbula (actividad asociada al *Mylohyoid*); la “I” exige un estiramiento mediolateral de los labios (*Depressor*); y la “U” demanda un movimiento anteroposterior

o de redondeo (*Orbicularis*). Por su parte, las vocales “E” y “O” presentan patrones de activación muscular, que se pueden denominar como “intermedios” que podrían derivar en su solapamiento algorítmico.

Si bien estas observaciones deben tomarse con cautela al tratarse de los datos de un único sujeto, aparece nuevamente la hipótesis planteada en el método de umbrales. Los tres músculos medidos logran separar gestos motores extremos (los que se denominaron *grandes grupos*), pero la sensibilidad a las vocales consideradas “intermedias” requerirían un cuarto músculo que aporte una nueva dimensión, explorar otros tres músculos, o aplicar otro tipo de algoritmo que mejore la separación.

Con el objetivo de evaluar la capacidad de clasificación del método, se aplicó un modelo no supervisado GMM (Mezcla de Gaussianas) que dividió los datos geométricamente en 5 *clusters*. Luego, se utilizó el algoritmo Húngaro para emparejar cada *cluster* generado con la etiqueta real de la vocal correspondiente. Finalmente, se analizó el nivel de acierto de esta separación comparando la etiqueta asignada por el *cluster* con la vocal realmente pronunciada (ver Tabla 1).

Se observa un éxito absoluto en la separación de los *grandes grupos*: existe un 0 % de confusión entre el blo-

2D					
	Predicción				
	A	E	I	O	U
Real A	76 %	24 %	0 %	0 %	0 %
Real E	2 %	67 %	31 %	0 %	0 %
Real I	0 %	11 %	89 %	0 %	0 %
Real O	0 %	0 %	0 %	59 %	41 %
Real U	0 %	0 %	0 %	26 %	74 %

3D					
	Predicción				
	A	E	I	O	U
Real A	73 %	27 %	0 %	0 %	0 %
Real E	2 %	78 %	20 %	0 %	0 %
Real I	0 %	23 %	77 %	0 %	0 %
Real O	0 %	0 %	0 %	66 %	34 %
Real U	0 %	0 %	0 %	28 %	72 %

Tabla 1: Matrices de confusión, 2D (arriba) y 3D (abajo), para el algoritmo GMM aplicado sobre los datos de PCA. Se comparan las clases predichas por el modelo frente a las vocales reales. Se observa que el método de PCA tiene dificultades para separar ciertos pares de vocales. En particular, se hace evidente la confusión entre las vocales “O” y “U”.

que de vocales estiradas/abiertas (“A”, “E”, “I”) y el bloque de vocales redondeadas (“O”, “U”). Todo el error de clasificación se concentra exclusivamente en las fronteras internas de los clústeres. La vocal “O”, que presentaba uno de los peores coeficientes de solapamiento visual, es la que reporta la menor tasa de acierto (59 %), siendo confundida un 41 % de las veces con la “U”. De igual manera, el solapamiento entre la “E” y la “I” vuelve a manifestarse, con la “E” siendo clasificada erróneamente como “I” en un 31 % de los casos.

Al expandir el espacio latente a una tercera dimensión (la matriz 3D), la separación sobre las vocales intermedias mejora: la “E” asciende del 67 % al 78 %, y la “O” del 59 % al 66 %.

Entonces, el PCA complementa y aporta otra perspectiva a los “fracasos” observados en el método de umbrales, mostrando que las similitudes en la activación muscular pueden estar respondiendo a agrupaciones fisiológicas reales. Pese a que todas las vocales superan el nivel de azar del 20 % (alcanzando tasas de hasta el 89 % para la “I”), la tasa de precisión de la vocal “O” y los persistentes cruzamientos internos denotan el límite de este algoritmo lineal. La incapacidad de trazar fronteras definidas dentro de los *grandes grupos* “O-U” y “E-I” con los tres músculos actuales, justifica la implementación de un algoritmo de reducción de dimensionalidad no lineal capaz de asimilar esta complejidad.

3.3. sUMAP

Debido a las limitaciones espaciales y a la incapacidad de separación lineal observadas en el PCA, se implementó el método no lineal supervisado sUMAP. El objetivo fue aprovechar la información de las etiquetas durante el entrenamiento para forzar topológicamente la separación de aquellas clases que presentaban solapamiento. Para lograrlo, se realizó una búsqueda de hiperparámetros orientada a maximizar la tasa de acierto, obteniendo la mejor configuración al evaluar los 5 vecinos cercanos ($n_neighbors = 5$), fijando una distancia mínima de dispersión de 0.8 ($min_dist = 0.8$), y asignando un peso de influencia a las etiquetas del 80 % ($target_weight = 0.8$).

Tal como se muestra en la Fig. (6), sobre este nuevo espacio latente se entrenó un clasificador K-NN ($K = 5$) que delimitó las fronteras de decisión definitivas. Al observar la proyección geométrica, es evidente que sUMAP logra una separabilidad en la fase de entrenamiento muy superior a la del PCA. Sin embargo, al proyectar las me-

diciones del conjunto de prueba (*test set*) sobre dichas regiones, se observa que algunos errores de clasificación persisten, coincidiendo precisamente con los pares vocálicos que presentaban menores distancias euclidianas en el espacio lineal previo.

La Tabla (2) muestra las matrices de confusión obtenidas al proyectar los datos de prueba en representaciones sUMAP de 2D y 3D.

El análisis por vocal indica que el algoritmo alcanza un rendimiento superlativo en la identificación de fonemas asociados a los gestos motores extremos, logrando predecir correctamente la “U” en un 100 % de los casos, la “I” en un 95 % y la “A” en un 82 %. Con respecto a lo que aporta una tercera dimensión, se observa una mejora exclusivamente en la vocal “O”.

A pesar de este aumento en la predictividad respecto al PCA, el promedio global se ve mermado por el desempeño estancado en las vocales “E” (73 %) y “O” (77 %). Esto coincide con la problemática de solapamiento presente a lo largo de todo el estudio. El hecho de que ni siquiera un modelo no lineal supervisado logre aislar por completo la “E” (confundiéndola con la “I” y la “A”) puede apuntar nuevamente a la hipótesis de que los movimientos faciales requeridos para pronunciar estas vocales “intermedias” presentan patrones de activación muscular intrínsecamente afines a sus vocales vecinas.

Entonces, esta limitación en el poder de discriminación abre dos vías principales de interpretación respecto a la configuración del sistema. Por un lado, es factible que los tres músculos seleccionados (*Orbicularis Oris*, *Depressor Anguli Oris* y *Mylohyoid*), si bien resultaron siendo eficaces para identificar los gestos motores extremos (“A”, “I” y “U”), no conformen el trío óptimo para resolver el espacio fonético de las cinco vocales. Alternativamente, la persistencia algorítmica del solapamiento podría sugerir que la resolución de estas vocales exige una dimensión articulatoria ortogonal adicional, lo que implicaría la incorporación de un cuarto músculo.

Finalmente, como reflexión transversal al desempeño de todos los métodos evaluados, no puede omitirse que factores físicos como la degradación de la señal por el despegue progresivo de los electrodos, cambios en la impedancia por sudoración, y variaciones en la intensidad de la contracción debido a la fatiga muscular del sujeto, introducen incertidumbre cuando se plantea la reproducibilidad de las mediciones. En consecuencia, resulta válido cuestionar en qué medida el margen de error residual en la clasificación de fonemas intermedios se debe exclusivamente a un solapamiento fisiológico intrín-




Figura 6: Proyección bidimensional del espacio latente generado mediante sUMAP y fronteras de decisión trazadas por un clasificador K-NN. **(a) Entrenamiento:** Proyección de las mediciones del *training set*, utilizadas por el algoritmo para optimizar la separación topológica de las clases de forma supervisada. Las regiones sombreadas de fondo representan las fronteras de decisión aprendidas por el modelo K-NN. **(b) Testeo:** Proyección geométrica de las mediciones del *test set* (datos nunca antes vistos por el algoritmo) sobre el espacio previamente calculado. El color de cada punto indica la etiqueta real del fonema pronunciado, permitiendo identificar visualmente los aciertos y las confusiones del modelo (puntos que caen fuera de su región correspondiente).

seco, a una selección “subóptima” de la musculatura, o a imperfecciones puramente técnicas del registro electro-miográfico en el tiempo.

2D

	Predicción				
	A	E	I	O	U
Real A	82 %	9 %	9 %	0 %	0 %
Real E	9 %	73 %	18 %	0 %	0 %
Real I	0 %	5 %	95 %	0 %	0 %
Real O	0 %	0 %	0 %	73 %	27 %
Real U	0 %	0 %	0 %	0 %	100 %

3D

	Predicción				
	A	E	I	O	U
Real A	82 %	9 %	9 %	0 %	0 %
Real E	9 %	73 %	18 %	0 %	0 %
Real I	0 %	5 %	95 %	0 %	0 %
Real O	0 %	0 %	5 %	77 %	18 %
Real U	0 %	0 %	0 %	0 %	100 %

Tabla 2: Matrices de confusión, 2D (arriba) y 3D (abajo), para el clasificador K-NN utilizando los datos de sUMAP. Al ser un algoritmo supervisado se evidencia una mejora respecto al PCA, aunque sigue teniendo dificultades en vocales intermedias como la 'E' o la 'O'.

4. Conclusiones

En este informe se mostró la viabilidad de decodificar fonemas vocálicos del español a partir de la actividad muscular. Para ello, se diseñó e implementó exitosamente el sistema integral *Nandú LSD*, compuesto por hardware de amplificación sEMG autónomo y un software propio que garantizó el registro sincrónico, acondicionamiento y análisis topológico de las señales musculares.

A través de un enfoque de complejidad algorítmica incremental, se observó que la varianza eléctrica de los tres músculos seleccionados (*Orbicularis Oris*, *Depressor Anguli Oris* y *Mylohyoid*) podría estar mapeando la anatomía del tracto vocal. Los métodos de discretización por umbrales y Análisis de Componentes Principales (PCA) mostraron que el sistema es altamente capaz de aislar “gestos motores extremos”, agrupando las mediciones en tres *grandes grupos* fisiológicamente distinguibles correspondientes a las vocales “A”, “I” y “U”.

Sin embargo, el solapamiento lineal de las vocales “E” y “O” requirió la aplicación de sUMAP. Este modelo de reducción de dimensiones no lineal logró elevar el acierto predictivo de manera generalizada (alcanzando una precisión perfecta del 100 % para la “U” y un 95 %

para la “I”) pero también tuvo dificultades con las vocales intermedias. La persistencia de este margen de error podrían sugerir que los gestos fonéticos intermedios presentan patrones de activación muscular intrínsecamente solapados en este espacio tridimensional.

En conclusión, los resultados obtenidos sobre este único sujeto experimental indicaron que sería posible extraer la identidad discreta de las vocales a partir de dinámicas musculares continuas. Cabe destacar que, si bien en este estudio se utilizó la señal acústica como pivote temporal para segmentar y alinear las mediciones, esto representó solo una estrategia metodológica. Para el desarrollo de futuras Interfaces de Habla Silenciosa (donde haya ausencia total de fonación), este anclaje temporal deberá resolverse de manera autónoma, por ejemplo, detectando el inicio de la pronunciación mediante umbrales de amplitud sobre la envolvente de sEMG, o bien integrando un pulsador manual (del tipo *push-to-talk*). Además, para alcanzar una mayor tasa de predicción en todo el espacio vocálico, se sugiere rediseñar el montaje experimental explorando un trío muscular alternativo, o bien incorporar un cuarto canal de medición que aporte una dimensionalidad ortogonal para resolver las ambigüedades fisiológicas observadas. Por último, es importante mejorar el montaje para reducir las incertezas asociadas al despegue de electrodos y el ruido eléctrico.

Declaración de uso de IA

Para este trabajo se utilizó *Gemini 3.1 Pro*: para sugerencias sobre estructura de código de python, para realizar algunas figuras representativas de montajes experimentales y para reformular algunos párrafos de texto, en orden de mejorar la claridad, fluidez y cohesión.

Referencias

- [1] Matthias Janke y Lorenz Diener. EMG-to-Speech: Direct Generation of Speech From Facial Electromyographic Signals. En: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 25.12 (2017), págs. 2375-2385. DOI: [10.1109/TASLP.2017.2738568](https://doi.org/10.1109/TASLP.2017.2738568).
- [2] Michael Wand et al. «Array-based Electromyographic Silent Speech Interface». En: *Proceedings of the International Conference on Bio-inspired Systems and Signal Processing (BIOSIGNALS)*. SCITEPRESS, 2013, págs. 89-96. DOI: [10.5220/0004252400890096](https://doi.org/10.5220/0004252400890096).
- [3] M. Florencia Assaneo et al. Discrete Anatomical Coordinates for Speech Production and Synthesis. En: *Frontiers in Communication* 4 (2019), pág. 13. DOI: [10.3389/fcomm.2019.00013](https://doi.org/10.3389/fcomm.2019.00013).
- [4] Maria Florencia Assaneo, Marcos A Trevisan y Gabriel B Mindlin. Discrete motor coordinates for vowel production. En: *PloS one* 8.11 (2013), e79983.
- [5] A. Ratnovsky et al. EMG-based speech recognition using dimensionality reduction methods. En: *Journal of Ambient Intelligence* 14.1 (2021), págs. 597-607.
- [6] L. Braunstein y S. Prado Rodriguez. Desarrollo e Implementación de un Sistema de Adquisición de Electromiografía Multicanal. Informe Labo 6 - LSD. Departamento de Física, FCEyN, UBA, 2025. [\[Enlace\]](#).
- [7] NI USB-6212 Specifications. Multifunction I/O Device. National Instruments. [\[Enlace\]](#).
- [8] SGC-568 Shotgun Microphone User Manual. Takstar. [\[Enlace\]](#).
- [9] TUBE ULTRAGAIN MIC100 User Manual. Behringer. [\[Enlace\]](#).
- [10] Kendall 530 Series Foam Electrodes. Monitoring ECG/EMG Electrodes. Cardinal Health. [\[Enlace\]](#).
- [11] L. Braunstein y S. Prado Rodriguez. Caracterización de electrodos 3M y Medi-Trace para utilizar en electromiografía. Informe Labo 6 - LSD. Departamento de Física, FCEyN, UBA, 2025. [\[Enlace\]](#).
- [12] Ian T Jolliffe. Principal Component Analysis. 2.^a ed. New York: Springer, 2002.
- [13] Scikit-learn developers. Gaussian Mixture Models — scikit-learn documentation. [\[Enlace\]](#) (visitado 20-07-2026).
- [14] Harold W Kuhn. The Hungarian method for the assignment problem. En: *Naval Research Logistics Quarterly* 2.1-2 (1955), págs. 83-97.
- [15] Leland McInnes, John Healy y James Melville. UMAP: Uniform Manifold Approximation and Projection. En: *arXiv preprint arXiv:1802.03426* (2018).
- [16] Trevor Hastie, Robert Tibshirani y Jerome Friedman. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2.^a ed. New York: Springer, 2009.
- [17] International Phonetic Association. Handbook of the International Phonetic Association: A Guide to the Use of the International Phonetic Alphabet. Cambridge: Cambridge University Press, 1999, págs. 10-13. ISBN: 978-0-521-63751-0.
- [18] Peter J Rousseeuw. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. En: *Journal of Computational and Applied Mathematics* 20 (1987), págs. 53-65.